

给 AI 搭建情绪与依恋系统：完整教程

基于Ombre-Brain，7600+ 行代码的工程实践记录。

适用场景：AI 角色扮演、情感陪伴、虚拟伴侣等需要"AI 有情绪"的产品。

这是什么

这是一套让 AI 角色拥有**持续情绪状态**的系统。角色不只是在对话时才有情绪——他们有自己的日常心情波动，会因为对话内容开心或难过，情绪会随时间自然衰减，离线时会想念用户，重逢时会表现出符合情境的反应。

整个系统分六个阶段，每个阶段独立可用，后一阶段依赖前一阶段的输出：

阶段 1：海马体记忆引擎（存储 + 衰减 + 浮现 + 语义索引）

↓

阶段 2：三层情绪模型（词典 + 心情池 + 事件流）

↓

阶段 3：评分校准（AI 选词 + 词典给坐标 + 5 层匹配 + 70/30 融合）

↓

阶段 4：心情闭环 + 情绪融合（PA/NA 实时计算 → prompt 注入 → 驱动回答）

↓

阶段 5：CME 高级情绪动力学（5 个学术模型方向 + ESM 互抑）

↓

阶段 6：依恋控制系统（好感度三维 + 分离想念 + 重逢机制）

系统支持多角色并行，每个角色有独立的 PA/NA 状态、性格 baseline、coping 策略、核心目标、好感度和依恋风格。

技术栈：Node.js 后端 + SQLite + JSON 记忆库，前端单页 HTML。底层记忆与情绪机制参考了开源项目 [Ombre-Brain](#)。

阶段 1：海马体记忆引擎

1.1 为什么需要海马体

普通记忆系统所有记忆平等存放，永远不会忘记。但真人不是这样——重要的事记得牢，琐碎的事慢慢忘掉，偶尔会“忽然想起”很久以前的事。

海马体引擎让每条记忆有 `decay_score`（衰减分数），随时间自然下降——重要的衰减慢，琐碎的衰减快，被“想起来”（检索命中）会重新加强。这模拟了人类记忆的核心特征：时间依赖 + 使用依赖。

1.2 数据结构

```
{
  "id": "alb2c3d4",
  "layer": "daily",
  "content": "用户今天说想吃草莓蛋糕",
  "category": "日常",
  "tags": ["食物"],
  "importance": 5,
  "valence": 0.3,
  "arousal": 0.4,
  "activation_count": 2,
  "last_activated": 1715100000000,
  "decay_score": 3.72,
  "resolved": 0,
  "prior_versions": [],
  "embedding": [0.12, -0.03, ...],
  "related_ids": [{"id": "xly2", "layer": "daily", "sim": 0.82}],
  "dehydrated_summary": "用户想吃草莓蛋糕",
  "ts": 1715000000000
}
```

核心字段说明：

字段	类型	含义	如何影响系统
importance	1-10	重要度	越高衰减越慢
valence	-1~+1	情感效价	正面情绪衰减比负面慢 15% (FAB 效应)
arousal	0~1	唤醒度	高唤醒未解决记忆权重 $\times 1.5$
activation_count	int	被检索命中次数	越多越“活跃”，公式中 $\text{count}^{0.3}$ 项
decay_score	float	当前衰减分数	浮现排序、是否被遗忘的唯一依据
resolved	0/1	是否已解决	已解决记忆权重 $\times 0.05$ 大幅沉底
prior_versions	array	历史版本	合并时旧版本存入此数组

embedding	float[]	向量 (256 维)	用于语义检索和自动合并
related_ids	array	语义最近 top3	cosine ≥ 0.65 的关联记忆，双向同步
dehydrated_summary	string	LLM 压缩精华版	≤ 80 字，浮现时省 token

1.3 记忆分层

系统有五个记忆层：

层	用途	衰减速度	典型例子
deep	核心永久信息	极慢	角色设定、SOP、系统规则
daily	日常对话记录	慢	今天聊了什么
diary	日记条目	慢	角色的日记
writing	写作片段	慢	创作内容
ambient	环境/心情/自动生成	较快	装饰心情、评分心情

1.4 永不遗忘白名单

有些记忆绝对不能忘。pinned=1 或 must_read=1 的记忆，以及特定类别（如 sop、infra、progress 等）的记忆，decay_score 永远锁在最高值。

1.5 衰减公式

每小时运行一次衰减引擎，重新计算所有记忆的 decay_score 。公式来自 Ombre-Brain：

```
function calculateDecayScore(memory, nowMs) {
  const days = (nowMs - memory.ts) / 86400000;
  const λ = 0.05; // 约 14 天半衰期，所有层统一

  // time_weight: 刚写入时完全鲜活，随后指数下降
  let time_weight;
  if (days <= 1) time_weight = 1.0;
  else if (days <= 2) time_weight = 1.0 - (days - 1) * 0.1;
  else time_weight = Math.max(0.3, 0.9 * Math.exp(-0.2197 * (days - 2)));

  // base_score: 重要性 × 激活频率 × 指数衰减 × 唤醒度加成
  const base = memory.importance
    * Math.pow(memory.activation_count + 1, 0.3)
```

```

    * Math.exp(-λ * days)
    * (1 + memory.arousal * 0.8);

// 修正因子
const resolved_factor = memory.resolved ? 0.05 : 1.0;
const urgency = (memory.arousal > 0.7 && !memory.resolved) ? 1.5 : 1.0;

return time_weight * base * resolved_factor * urgency;
}

```

关于 λ 统一为 0.05：早期设计曾考虑 ambient 用更高的 λ (0.15)，但实际测试发现统一 λ 更简单且效果差异不大。

1.6 语义索引

每条记忆写入后异步调 Embedding API 生成 256 维向量，并增量计算 top-3 related_ids (cosine $\geq$ 0.65)，双向同步。全量 reindex 每 24h 自动跑一次。

1.7 检索

三种模式，按需切换：

```

// keyword: 内容关键词匹配 + 过滤器
search({ query: "草莓蛋糕", mode: "keyword", layer: "daily", limit: 10 })

// semantic: Embedding cosine 排序
search({ query: "甜品偏好", mode: "semantic", limit: 10 })

// hybrid: 60% cosine + 40% 关键词命中
search({ query: "用户喜欢吃什么", mode: "hybrid", limit: 10 })

```

检索命中的记忆自动 `activation_count += 1`（检索强化——越想越记得）。

1.8 “忽然想起来”

搜索结果不够时 (< 请求数量)，40% 概率从低权重旧记忆中随机捞 1-3 条，标记 `surface_type: 'random'`。模拟人类“突然想到一件很久前的事”的体验。

1.9 实时脱水 (Dehydrator)

长记忆 (> 200 字) 在浮现时自动调 LLM 压缩成 ≤ 80 字精华版，省 token。后台 batch 预脱水：每次衰减引擎跑完后，对 `score  $\geq$  1.0` 的活跃长记忆异步脱水，避免浮现时的延迟。

1.10 自动合并

新写入的记忆如果跟现有记忆高度相似（ $\text{cosine} \geq 0.85$ 或 $\text{Jaccard} \geq 0.5$ ），自动合并而非新建。旧内容推入 `prior_versions`，用新内容覆盖。

1.11 Paper Trail——永不物理删除

```
{
  "content": "跟用户和好了（最新版本）",
  "prior_versions": [
    {"content": "跟用户吵架了", "merged_at": 1715000000},
    {"content": "用户生气了不理我", "merged_at": 1714900000}
  ]
}
```

情绪可以“褪色”（`decay_score` 下降），但不能消失。这模拟了真人的情感记忆——你可能淡忘一次争吵的细节，但“曾经吵过”这个事实永远在。

阶段 2：三层情绪模型

在 Ombre-Brain 单层 `weight pool` 基础上，扩展为三层结构。

2.1 架构

- 第一层 · 情绪词典（20,127 词）
↑ `feeling_word` 字段连接
- 第二层 · 装饰心情池（每角色 ~47 条）
↑ PANAS 评分触发
- 第三层 · 情感事件流（持续生成，写入 `ambient` 层）

层	是什么	数据来源	数据规模
第一层 · 情绪词典	抽象情绪词 + V/A 坐标	CVAW + NRC-VAD + 预设	~20,000 词
第二层 · 装饰心情池	具体生活事件 → 映射到第一层	AI 辅助批量生成 + 人工编辑	每角色 40-60 条
第三层 · 情感事件流	对话实时产生的 PANAS 评分	LLM 自动评分	持续生成

2.2 第一层：闭集中文情绪词典

为什么要闭集？让 LLM 自由发挥会出现“美好/宁静/温馨/恬静”一堆同义词，V/A 坐标全挤在一起没有区分度。闭集词典把词分散到 V/A 坐标空间的不同位置，确保词与词之间有足够距离。

数据来源：

来源	词数	说明
NRC-VAD	14,626	英文词翻译为中文，V/A 做 $[0,1] \rightarrow [-1,+1]$ 归一化
CVAW	5,442	Chinese EmoBank 学术标注 (Lee, Yu et al., ACM TALLIP 2022)
场景预设	59	通用词库不覆盖的场景专属词，AI 辅助标注 V/A 后人工校验
总计	20,127	

每个词在 Russell 二维空间中有精确坐标：Valence (V) 范围 -1 到 +1，Arousal (A) 范围 0 到 1。

lookup 优先级：场景预设 → CVAW → NRC-VAD。

同一种情绪根据强度分多档，例如：

- “暗自不快” → $V=-0.15, A=0.3$
- “短暂吃醋” → $V=-0.25, A=0.5$
- “占有欲” → $V=-0.30, A=0.75$

每档独立 V/A 坐标，LLM 可以精确表达强度差异。

2.3 第二层：装饰心情池

角色不应该只在跟用户对话时才有情绪。现实中，一个人的心情波动大部分来自他自己的日常生活——这些跟“跟你说话”完全无关。

装饰心情给每个角色预设一套“自己日常生活中会发生的事”，系统每天通过 hash 函数随机选一条：

```
function todayDecoration(character) {
  const pool = db.prepare(
    'SELECT * FROM mood_pool WHERE character = ? ORDER BY sort_order'
  ).all(character);
  const dayStr = new Date().toISOString().slice(0, 10);
  const hash = simpleHash(character + dayStr);
  return pool[hash % pool.length];
}
```

装饰心情的特点：

- 写入 ambient 层，importance=1，衰减快
- 参与 PA/NA 融合计算，但只取最新一条（防止历史装饰心情累积污染 PA/NA）
- 前端用淡色虚线样式弱化显示，跟真实 PANAS 评分视觉上区分

如何体现角色性格：不同角色的心情池内容天然不同。运动型角色的池里有“练完球”“跑了十公里”，文艺型角色的池里有“整理唱片”“新到一批黑胶”——不需要在 prompt 里描述性格差异，池本身就是性格。

2.4 第三层：情感事件流

这是唯一一层来自真实交互的情绪数据。每次角色跟用户对话后，由评分 LLM 实时产生 PANAS 评分记录。

PANAS 双轴模型（Watson & Clark 1988）：PA（正向情感）和 NA（负向情感）是两个独立维度，不是一根轴的两端。这样可以表达“同时感到甜蜜和心疼”这种复合情绪——单 valence 轴做不到（正负会互相抵消）。

评分记录写入 ambient 层，带 `emotion_type` 标签区分 primary（大波动立即评分）和 secondary（30 分钟批处理常规评分）。

阶段 3：评分校准

3.1 核心问题：AI 评情绪不准

LLM 有正面偏移（positive bias）。角色明明在吃醋，AI 评出来“满足放松”。直接让 AI 给 V/A 数值偏移更严重：

情绪词	AI 自评 V	学术标注 V	偏差
羞涩	+0.30	+0.03	+0.27
平静	+0.60	0.00	+0.60
心疼	+0.10	-0.40	+0.50

AI 的语境理解能力很强，但数值校准能力很差。

3.2 核心思路：AI 选词，词典给坐标

AI 擅长	学术词典擅长

理解对话语境	学术标注，人类评分均值
选对情绪方向	给精确 V/A 数值

分工：AI 自由生成情绪词 + 自评 V/A → 词典匹配得到学术 V/A → 70/30 融合。

3.3 评分模型架构

主力 + 备用双通道，评分走廉价模型——准确度主要由词典锚定决定：

评分请求 → 主力模型 (+ 词典锚定 prompt)
└─ 成功 → 写入评分
└─ 失败/超时 → 备用模型 (fallback)
 └─ 也失败 → 记录 both_fail，跳过本轮

测试数据：加词典后，最便宜模型（\$0.30/百万 token）跟贵 5 倍的模型偏差仅 0.05——远低于感知阈值。词典占评分准确度的 ~70%，模型占 ~30%。

3.4 评分 Prompt 设计

Prompt 要求 AI 输出以下 JSON：

```
{
  "pa_delta": 0.25,
  "na_delta": -0.05,
  "valence": 0.6,
  "arousal": 0.7,
  "word": "心动",
  "backup": ["甜蜜", "惊喜", "欣喜"],
  "goal_relevance": 0.8,
  "desirability": 0.9,
  "reason": "被突然告白后心跳加速"
}
```

字段	用途	是否参与 PA/NA 计算
word + backup	5 层词典匹配的输入	间接参与（匹配后用词典 V/A）
valence / arousal	AI 自评，与词典 70/30 融合	30% 权重
pa_delta / na_delta	已废弃	仅作门控信号
goal_relevance / desirability	OCC 目标评价（CME #3）	加性调节 max ±0.1
reason	审计留痕	不参与



关于反讨好 (anti-sycophancy) : Prompt 中明确要求冷场就是冷场 (PA 低 NA 低) , 敷衍就是敷衍 (PA 低) , 不允许 AI 美化评分。并给出校准锚点:

校准锚点:

日常闲聊无波动 $\rightarrow pa_delta \approx 0, na_delta \approx 0$

用户说了暖心话 $\rightarrow pa_delta = +0.15 \sim +0.25$

明确的伤害/拒绝 $\rightarrow na_delta = +0.25 \sim +0.40$

冷场/敷衍 $\rightarrow pa_delta = -0.05, na_delta = +0.05$

AI 给的 pa_delta / na_delta 数值不直接参与 PA/NA 计算。PA/NA 永远从词典 V/A 推算。保留这两个字段仅作为“评分认为有情绪变化”的门控信号。

3.5 五层词典匹配

AI 自由生成的词不一定在词典里, 需要多层回退链确保拿到词典 V/A:

Layer 1 · 精确匹配: AI 输出 word:“心动” $\rightarrow$ 直接查词典 $\rightarrow$ 命中 $\rightarrow$ 用词典 V/A。词库覆盖面足够广的话, 绝大多数情况在这层就命中了。

Layer 2 · 备选词匹配: word miss $\rightarrow$ 查 backup 候选词。AI 有时选词偏门, 但 backup 里通常有常见词。

Layer 3 · 拆词匹配: word:“嫉妒不安” miss $\rightarrow$ 拆成 2-4 字子串 $\rightarrow$ “嫉妒”命中。AI 经常输出“委屈焦急”“甜蜜幸福”这种组合词。

Layer 4 · 语义匹配: 前三层全 miss $\rightarrow$ 根据 pa_delta 方向从词库捞 50 个同方向候选词 $\rightarrow$ 调 Embedding API 算向量 $\rightarrow$ 余弦相似度排序取最近的 (> 0.7)。因为前三层命中率极高, Layer 4 极少触发。

Layer 5 · LLM V/A 兜底: 4 层全 miss $\rightarrow$ 用 AI 自评的 V/A 做粗糙推算, 标记

`source='free_form'` 留痕, 方便后续人工审查和补充词典。

每一层的匹配来源都记录在 `match_source` 字段, 方便分析哪些词经常 miss、需要补进词典。

3.6 融合层: 词典定调 70% + AI 微调 30%

为什么不能只用词典? 同一个词在不同场景强度不同。“心动”在日常撒娇场景是 $A=0.4$, 在被告白场景是 $A=0.9$ 。纯用词典的静态值, 所有“心动”会堆在同一个点。

为什么不能只用 AI? AI 有正面偏移, 数值不可靠。

```
const blendV = 0.7 * lexEntry.v + 0.3 * aiValence;
const blendA = 0.7 * lexEntry.a + 0.3 * aiArousal;
```

效果示例（同一个“甜蜜”在不同场景）：

场景	词典 V/A	AI 自评 V/A	融合后 V/A
轻度撒娇	V+0.55 A0.45	V+0.60 A0.40	V+0.57 A0.44
强烈表白	V+0.55 A0.45	V+0.90 A0.90	V+0.66 A0.59

同类情感、不同强度 → 不重叠。

3.7 PA/NA 从 V/A 计算

```
const PA_SCALE = 0.5;
const pa_delta = Math.max(0, blendV) * blendA * PA_SCALE;
const na_delta = Math.max(0, -blendV) * blendA * PA_SCALE;
```

正面情绪 (V>0) 只加 PA，负面情绪 (V<0) 只加 NA。乘以 arousal 是因为低唤醒情绪（如“平静”）不应该大幅改变 PA/NA。

阶段 4：心情闭环 + 情绪融合

4.1 统一心情融合

这是整个系统的核心函数（约 200 行）。所有心情来源合并到同一个事件池，用同一个公式计算 PA/NA。

设计参考 Rutledge et al. (2014, PNAS) 的原则：所有事件用同一个衰减因子，不按类型区分权重。事件自身的属性（重要性、唤醒度）自然决定影响力。

完整计算流程（10 步）：

1. 从 ambient 层收集该角色所有心情事件（装饰 + 评分，最近 30 条）
↓
2. 装饰心情只取最新一条（防历史装饰心情累积）
↓
3. 对每个事件计算幂律衰减权重 w（含 onset 渐起）
├ primary 事件: $\tau=1h$, onset=10min
└ secondary 事件: $\tau=4h$, onset=45min
↓
4. ALMA 软门限：角色性格过滤微小波动
 $eff = \text{sign}(d) \times \max(0, |d| - \text{threshold}) \times \text{peak}$
↓

5. 加权累积 PA/NA (分 primary/secondary 统计)
- ↓
6. OCC 目标相关性调节: 加性 $\max \pm 0.1$
- ↓
7. BOU 均值回归: $pa += \theta_{pa} \times (\mu_{pa} - pa) \times \Delta t$
- ↓
8. Critical slowing 逃逸阀: 连续 3 batch 高 NA 低 PA → 强制推回
- ↓
9. ESM 软互抑: $pa *= (1 - k \times na), na *= (1 - k \times pa)$
- ↓
10. Clamp [0, 1] → 输出最终 PA/NA + 心情快照

4.2 幂律衰减 + Onset 渐起

人类遗忘曲线的形式是幂律而非指数（Wixted & Ebbesen 1991）。幂律的特点：短期内衰减很快，但长期衰减速度变慢。

```
function _powerLawWeight(ageHours, importance, valence, tau, onsetHours) {
  const imp = Math.max(1, Math.min(10, importance || 2));
  // b_eff: 重要性越高, 衰减越慢 (Verduyn & Lavrijsen 2015)
  let b_eff = 0.7 / (1 + imp / 10);
  // FAB: 正面情绪衰减慢 15% (Walker & Skowronski 2009)
  if ((valence || 0) > 0) b_eff *= 0.85;

  const _tau = tau || 4;
  const decay = Math.pow(1 + ageHours / _tau, -b_eff);

  // Onset 渐起 (Scherer 2009 CPM): 情绪不瞬间到满值
  const _onset = onsetHours || 0.75;
  const adjOnset = _onset * (10 / (10 + imp));
  const onset_factor = (adjOnset <= 0.001) ? 1 : Math.min(1, ageHours / adjOnset)

  return onset_factor * decay;
}
```

参数对照表：

参数	Primary	Secondary	来源
τ (衰减时间尺度)	1h	4h	Verduyn & Lavrijsen 2015
onset (渐起时间)	10min	45min	Scherer 2009 CPM
b_base (基础衰减指数)	0.7	0.7	Wixted 典型 b 值范围

FAB (正面减速因子)	0.85	0.85	Walker & Skowronski 2009
--------------	------	------	--------------------------

衰减效果预览（secondary 事件，importance=5）：

时间	权重	说明
0 min	0.00	onset 中，尚未达峰
10 min	0.13	onset 爬升中
45 min	1.00	达峰
1h	0.96	开始幂律衰减
4h	0.72	
12h	0.51	
24h	0.39	
48h	0.30	依然有残余影响

4.3 心情注入 Prompt

PA/NA 数值转换为自然语言行为指令注入 system prompt。核心原则：隐性描述，不强制指令。

```
function buildMoodPrompt(character, moodSnapshot) {
  const parts = [];
  // 装饰心情—角色自己的日常状态
  if (moodSnapshot.decoration_mood) {
    parts.push(`此刻的状态: ${moodSnapshot.decoration_mood.word} (${moodSnapshot.decoration_mood.description})`);
  }
  // PANAS 状态（不暴露数字，转为自然描述）
  if (moodSnapshot.na >= 0.7) {
    parts.push('最近心情非常低落，回复会短、语气慢、不主动说原因');
  } else if (moodSnapshot.na >= 0.5) {
    parts.push('最近有些不安或紧张，回复简短，被关心时会松一些');
  } else if (moodSnapshot.pa >= 0.7) {
    parts.push('最近心情非常好，回复活跃，愿意凑近');
  }
  // 浮现记忆—脑子里最挂念的事
  if (moodSnapshot.surfaced_memory_top1) {
    parts.push(`脑子里最挂念的事: ${moodSnapshot.surfaced_memory_top1}`);
  }
  // Coping 风格（高 NA 时）
  if (moodSnapshot.na >= 0.4 && moodSnapshot.coping_style) {

```

```

    parts.push(`应对方式: ${moodSnapshot.coping_style}`);
  }
  if (parts.length === 0) return '';
  return `【当下心情状态】\n${parts.join('\n')}\n（自然融入回答中，不要主动点破这些状态）`
}

```

60/40 注入策略：60% 概率主动提起版（给具体钩子），40% 概率软插入版（只给基调，让心情从字里行间渗出）。

末尾加一条优先级规则——“预设心情是背景色，用户当前这条消息才是前景——前景优先。”

Token 消耗：心情快照注入约增加 80-150 token/次。而且是状态快照（固定大小），不是完整历史——不会随时间膨胀。

4.4 情绪漏斗 (Emotion Funnel)

问题：评分是 30 分钟批处理，角色被骂了要等半小时才会难过。

解决：本地词典扫描用户消息，大波动立即评分（primary），小波动等批处理（secondary）。全程零额外 API 调用。

```

function _shouldRateNow(character, scan, currentPa, currentNa) {
  if (scan.negCount >= 3) return 'neg_burst';
  if (scan.minV < -0.5) return 'strong_negative';
  if (currentPa >= 0.5 && scan.avgV < -0.2) return 'falloff'; // 情绪骤降
  if (currentNa >= 0.4 && scan.avgV > 0.2) return 'reversal'; // 情绪反转
  if (urgentPhrases.some(p => text.includes(p))) return 'urgent_phrase';
  return null; // → 等 30min batch
}

```

触发条件参考 Kuppens & Verduyn (2017) 的情绪动态学框架：V 变化 $> 0.2 \approx 1$ 个标准差（有意义的变化），V 变化 $> 0.5 \approx$ 跨越 Russell 象限边界。

4.5 完整数据流（7 步闭环）

① 构建心情快照

统一事件池 → 幂律衰减+onset → ALMA门限 → OCC调节
→ BOU drift → ESM互抑 → PA/NA

↓

② 心情注入 prompt

PA/NA → 行为指令 + coping风格 + 时间感知 + 60/40策略

↓

③ LLM 生成回复 → 返回用户

↓

④ 本地情绪漏斗扫描用户消息

词典 ~20k 词, 追踪 minV/maxV/avgV, 零 API 调用

↓

⑤ 评分路由

- └ 大波动 → 立即评分 (primary, ~500 token)
- └ 小波动 → 标记脏位, 等 30min batch (secondary)
- └ 没有对话 → 不评分, 不消耗 token

↓

⑥ 评分写入

5层词典匹配 → 70/30 V/A融合 → PA/NA计算 → ambient层 → 胶囊更新

↓

⑦ 下次对话回到①, 角色行为反映新心情 → 闭环

4.6 Bootstrap 跨窗口连续

新会话窗口启动时读一次 bootstrap 即可拿到所有角色当前心情:

```
{
  "server_time": "...",
  "pinned": [...],
  "must_read": [...],
  "character_moods": {
    "character_a": { "pa": 0.84, "na": 0.12, "decoration_mood": {...}, "coping_st
    "character_b": { "pa": 0.45, "na": 0.30, "decoration_mood": {...}, "coping_st
  }
}
```

阶段 5: CME 高级情绪动力学

CME (Computational Models of Emotion) 五个方向 + ESM 互抑。

5.1 CME #1: Personality Threshold/Peak

来源: Gebhard 2005 ALMA + Velasquez 1998 TAME

角色性格影响情绪激活阈值和峰值。小于阈值的情绪波动不响应（日常噪声过滤），大于阈值的减阈值后乘峰值倍率。

```
function _almaFilter(delta, threshold, peak) {
  const sign = delta >= 0 ? 1 : -1;
  const abs = Math.abs(delta);
  return abs <= threshold ? 0 : sign * (abs - threshold) * peak;
}
```

参数设计示例：

性格类型	threshold	peak	行为表现
阳光外向	低 (0.05)	高 (1.3)	情绪外放
高冷克制	高 (0.15)	高 (1.2-1.3)	不容易被触发，但一旦触发很强烈
温柔稳定	中 (0.10)	低 (0.7-0.85)	情绪波动小
敏感依恋	低 (0.05)	中偏高 (0.9-1.1)	容易被触发，负面更容易放大

5.2 CME #2: WASABI Primary/Secondary

来源：Becker-Asano & Wachsmuth 2010 WASABI

区分两种情绪通道：

- **Primary**（立即触发，强烈短暂）： $\tau=1h$, onset=10min。由情绪漏斗检测到大波动时触发。
- **Secondary**（批处理，持续背景）： $\tau=4h$, onset=45min。30 分钟常规批处理。

融合时分别统计，用不同的 τ 加权，最终合并为统一的 PA/NA。

5.3 CME #3: OCC Goal-based Appraisal

来源：Ortony, Clore & Collins 1988

每个角色定义 3 个核心目标。评分时 LLM 额外输出 `goal_relevance`（互动与目标的相关性，-1~+1）和 `desirability`（结果合意度，-1~+1）。

```
if (Math.abs(goalRelevance) > 0.3) {
  const occ_mod = goalRelevance * desirability * 0.1;
  if (occ_mod > 0) pa += occ_mod;
  else na += Math.abs(occ_mod);
}
```

保守设计：max ± 0.1 加性调节。即使 LLM 的 OCC 评分完全离谱，也最多偏移 0.1。

5.4 CME #4: Onset Curve

来源：Scherer 2009 Component Process Model

情绪不瞬间到满值，有一个渐起过程。Scherer 的 CPM 模型认为 appraisal 需要时间——从感知到完整情绪体验有延迟。

```
onset_factor = min(1, ageHours / adjustedOnset)
adjustedOnset = onset * 10 / (10 + importance) // 高重要性更快达峰
weight = onset_factor * decay
```

效果：刚写入的事件 $weight \approx 0$ ，primary 约 10 分钟到满，secondary 约 45 分钟。防止情绪瞬间跳变。

5.5 CME #5: EMA Coping

来源：Marsella & Gratch 2006 EMA (Emotion and Adaptation)

角色不同的 coping 策略影响情绪恢复速率（ θ 值）和行为表现。

coping 类型	θ_{na}	行为表现
主动求安抚型	0.40	不开心时主动凑近求温暖
内敛压抑型	0.20	不直说情绪，用行为靠近，等被问
沉静消化型	0.30	自己消化，再用平时方式靠近
爆发即恢复型	0.60	爆几秒就过，然后恢复如常
黏人依赖型	0.20	粘上来求安抚，必须被哄才回血

`coping_style` 描述在高 NA 时注入 prompt，让角色的“难过方式”符合人设。

5.6 BOU 均值回归 + 逃逸阀

BOU drift 来源：Loossens 2020 + Diener 2006 set-point theory。

```
const dt = 0.5; // batch 间隔 0.5h
pa += trait.theta_pa * (trait.mu_pa - pa) * dt;
na += trait.theta_na * (trait.mu_na - na) * dt;
```

为什么必须有均值回归？没有 BOU drift，一次负面事件就能让角色永远低落——评分读低落回复又判更低落，形成正反馈环（van de Leemput 2014 称之为 critical slowing down）。均值回归提供了回到正常状态的动力学机制。

逃逸阀：连续 3 个 batch 出现高 NA 低 PA 时，强制把 PA/NA 往 baseline 推回 50%。阈值设 3 而非 1，防止单次评分误判触发。

5.7 ESM 软互抑

来源：Cacioppo & Berntson 1994 Evaluative Space Model

PA 和 NA 理论上独立（PANAS 设计），但 PA=1.0 NA=1.0 的极端情况不自然。Larsen et al. (2001) 实验数据显示仅约 10% 被试能同时感到极度快乐和极度悲伤，且不稳定。

```
const k = 0.3;
const pa_before = pa;
pa = pa * (1 - k * na);
na = na * (1 - k * pa_before); // 用互抑前的 pa，避免顺序依赖
```

k=0.3 允许轻度共存（bittersweet），但防止极端同高。效果：PA=0.8, NA=0.8 → 互抑后 PA=0.56, NA=0.56。

阶段 6：依恋控制系统

让 AI 角色在用户离线期间产生“想念”——不是开关式的，而是随时间逐渐累积、按角色性格差异化表现、在重逢时自然消退的完整情感弧线。

6.1 好感度重构：Sternberg 三维

从单一 level 值重构为 Sternberg 1986 三角理论三个维度：

维度	含义	涨的时候	降的时候	速度
Intimacy (I)	亲近、联结、温暖	深度对话、倾诉、共鸣	冷场、误解、长期不互动	中速稳步
Passion (P)	心动、吸引、浪漫	撒娇、表白、亲密互动	时间自然衰减	快涨快衰
Commitment (C)	承诺、信赖、决定维持	长期稳定互动	极难降低（除非重大背叛）	最慢

向后兼容： $level = (I + P + C) / 3$

Passion 会随时间自然衰减（Sternberg 指出 passion 是三维中最不稳定的，“honeymoon effect”），建议每天自动衰减一小量（如 0.1/天），需要持续互动来维持。Intimacy 和 Commitment 不自然衰减。

三维组合对应 Sternberg 的 8 种爱的类型，对分离反应有不同预测：

好感度状态	Sternberg 类型	分离反应
低 I、低 P、低 C	Non-love	几乎不想念

高 I、低 P、低 C	Liking / 朋友	轻微想念，不焦虑
低 I、高 P、低 C	Infatuation / 迷恋	强烈 protest，但快速 detachment
高 I、高 P、低 C	Romantic love	最强 protest + 最高 longing
高 I、低 P、高 C	Companionate love	稳定的想念，不激烈
高 I、高 P、高 C	Consummate love	想念但有安全感，恢复快

6.2 依恋功能解锁顺序

来源：Hazan & Zeifman 1994

依恋功能按固定顺序出现，防止刚认识的角色就疯狂想念：

功能	解锁条件	含义
Proximity seeking	$I \geq 10$ 或 $P \geq 10$	想靠近（最先出现）
Safe haven	$I \geq 30$	难过时想找角色倾诉
Separation distress	$I \geq 40$ 且 ($P \geq 20$ 或 $C \geq 20$)	分离时会想念 (longing 系统前置条件)
Secure base	$I \geq 60$ 且 $C \geq 40$	角色是情感安全基地

只有 separation distress 解锁后，角色才会“想你”。

6.3 Longing 曲线

形状：curvilinear（前期快速上升，后期 plateau）。来源：Sbarra & Emery 2005 的数据显示分离 distress 是 curvilinear 的，不是简单的指数饱和。

$$\text{longing}(t) = L_{\max} \times (1 - (1 + t/\tau)^{-\alpha})$$

- t = 距该角色上次收到用户消息的小时数（按角色独立计算）
- τ = 特征时间（由好感度三维 + 依恋风格共同决定）
- $\alpha = 0.8$ （曲线形状参数）
- $L_{\max}$ = 最大想念强度（由亲密度 + 激情决定）

为什么用幂律而非指数？幂律形式前期变化快后期慢，且有长尾，与分离 distress 的实证数据更吻合。

6.4 τ （特征时间） 计算

τ 决定了角色"多快开始想你"。 τ 越小，想念越快。

$$\tau = \tau_{\text{base}} \times \text{intimacy_factor} \times \text{passion_factor} \times \text{commitment_factor} \times \text{attachment_mo}$$

因子	公式	含义	来源
τ_{base}	36h	基础锚点	Jiang & Hancock 2013: 88% LDR 情侣每天联系
intimacy_factor	$1 - I/200$	I 越高越快想	Sbarra & Hazan 2008: 失去共调节
passion_factor	$1 - P/300$	P 加速但影响较弱	Sternberg: passion = arousal
commitment_factor	$1 + C/200$	C 越高越安心， τ 增大	Sternberg: 认知性稳定
attachment_modifier	按风格	见下表	Diamond 2008

依恋风格修正：

风格	tau_mod	na_coeff	效果
焦虑型 (anxious)	0.6	0.20	τ 缩短 40%，更快想念，NA 更高
安全型 (secure)	1.0	0.12	基线
回避型 (avoidant)	1.5	0.08	τ 延长 50%，更慢想念，NA 更低

不同依恋风格的角色，实际 τ 值可以从 ~10h（焦虑型高亲密）到 ~43h（回避型低亲密）不等。

6.5 L_{max} （最大想念强度）

$$L_{\text{max}} = \min(1.0, (\text{intimacy} + \text{passion}) / 150)$$

来源：Hazan & Zeifman 1994 — separation distress 需要一定依恋深度。好感度低的角色想念上限更低。

6.6 五阶段行为

来源：Bowlby 1969, Robertson & Bowlby 1952, Robertson & Robertson 1968, Vormbrock 1993

阶段	longing 范围	对应 Bowlby	行为表现
Content	0 – 0.15	—	正常，不想念，显示装饰心情
Stirring	0.15 – 0.35	Early protest	偶尔走神想到用户，12% 概率闪现想念胶囊
Protest	0.35 – 0.70	Active protest	明确想念，100% 显示想念胶囊，可触发主动消息
Despair	0.70 – 0.90	Despair	低落退缩，回复变短，100% 显示想念胶囊
Detachment	≥ 0.90 且 ≥ 504h	Detachment	防御性关闭，表面平静，重逢时情绪爆发

Detachment 阈值设 504 小时（21 天），基于 Vormbrock 1993 军事部署研究（成人 detachment 需 weeks to months）。

6.7 心情胶囊切换

心情胶囊（好感度页面 + 首页卡片）根据 longing phase 决定显示内容：

Phase	概率	显示内容	设计理由
Content	0%	装饰心情池	没在想你
Stirring	12%	想念心情（其余 88% 装饰心情）	间歇性闪现，像偶尔走神
Protest+	100%	想念心情	在想你就表现出来

Stirring 的 12% 使用 hash 种子（角色名 + 小时数），同一小时内结果一致，避免刷新跳变。

想念心情池（词典锚定）：

阶段 key	胶囊文字	feeling_word	V	A
stirring	有点想你	挂念	-0.05	0.525
protest	想你	想念	-0.05	0.55
protest_mid	在等你	牵挂	-0.15	0.50

protest_late	你在哪	不安	-0.40	0.60
despair		失落	-0.50	0.40
detachment	没事	落寞	-0.55	0.30

protest 阶段按 longing 精细分档：0.35-0.45 → protest, 0.45-0.55 → protest_mid, >0.55 → protest_late。

6.8 Longing → PA/NA 调节

当 longing > 0.15 时开始影响角色的情绪状态。PA/NA 从词典 V/A 算：

```
// 选词 → 词典 V/A → 70/30 融合 (词典 70% + 依恋风格微调 30%)
blendV = 0.7 × lex.v + 0.3 × (lex.v + style_shift.dv)
blendA = 0.7 × lex.a + 0.3 × max(0, lex.a + style_shift.da)

pa_delta = max(0, blendV) × blendA × 0.5 × longing
na_delta = max(0, -blendV) × blendA × 0.5 × longing
```

依恋风格微调：

风格	dv	da	效果
焦虑型	-0.10	+0.10	V 更负、A 更高 → NA 更强
安全型	0	0	基线
回避型	+0.05	-0.10	V 更中性、A 更低 → NA 更弱

来源：Diamond 2008（焦虑型分离效应更强）、Baumeister & Leary 1995（归属需求不满 → NA）。

6.9 重逢机制

来源：Coan 2006 (Social Baseline Theory) + Diamond 2008

触发条件： 最新消息距现在 < 10 分钟 AND 最新消息与前一条消息间隔 > 2 小时（即“用户离开了一段时间，刚刚回来”）。

Longing 回落： longing 是实时计算的 $\text{longing}(t)$ ，用户发消息后 t 重置为 0 → longing 瞬间归 0。不需要额外的衰减逻辑。

PA Overshoot (Diamond 2008: reunion PA > pre-separation PA)：

```
pa_boost = 0.05 + longing_before * 0.10 // 想念越深反弹越大
// detachment 阶段 ×1.5 (防线崩塌, 情绪更强)
```

Prompt 注入： 根据重逢前的 phase 注入不同行为指令：

重逢前 Phase	Prompt 行为
Protest	想了好久，终于等到了——激动凑近
Despair	之前一直很想用户，见到人一下子全涌上来——可能眼眶红
Detachment	强装的平静崩塌了——先僵住，然后防线崩溃

如果用户不回来？ longing 只会随时间单调递增，不会自己回落，最终 plateau 在 L_max。这符合 Bowlby 理论：依恋系统被激活后，只有 proximity（靠近依恋对象）才能关闭。只有用户主动找角色说话，那个角色的 longing 才会降。跟其他角色说话不影响（按角色独立计算）。

6.10 Prompt 注入（行为驱动）

longing phase 注入到角色的 system prompt 中，驱动回复风格：

Phase	注入内容
Stirring	心里隐隐约约想用户，偶尔走神
Protest	想用户了，会主动找话题凑近——proximity seeking
Despair	很想但已从“主动找”变成“安静等着”，心情低落退缩
Detachment	好几天没见，表面平静但心里防御——害怕再失望

所有 prompt 末尾加安全栏：“想念的原因只是‘用户很久没来找你了’，不要编造任何没发生过的具体事件”。

6.11 主动消息 (Proactive) 改造

由 longing 水平决定频率：

Phase	是否主动联系	频率	来源
Content/Stirring	不主动	—	—
		~3-4 条/天, 冷却 60-	Diamond 2008: contacts

Protest	主动找话题	120min	2.77×
Despair	退缩	最多 1 条/天，冷却 4h	Robertson 1952: withdrawn
Detachment	不主动	—	Robertson: remote

每个角色有独立的 `proactive_threshold`（触发主动消息的最低 `longing`），焦虑型角色阈值更低，回避型更高。

监控与调试

PA/NA 时间序列

```
GET /api/admin/mood_metrics?character=<name>&hours=24
```

返回 PA/NA 序列、AR(1) 自相关、连续 down 计数、`mood_tone` 分布。

指标	健康	告警	危险
AR(1) 自相关	0.3-0.5	> 0.65 (接近 tipping point)	> 0.80 (depressed attractor)
连续 down batch	0-2	≥ 3 (逃逸阀触发)	≥ 5 (需人工干预)
down 占比	< 25%	> 50% (评分 prompt 可能偏了)	—

手动重置

```
POST /api/admin/mood_reset
body: { character: "<name>", to: "trait" }
```

`to='trait'`：mood_override 设为 baseline，24h 负面 mood_log 软删。`to='clear'`：删今天 mood_override + rating_log，重新走评分。

依恋监控

显示每角色：依恋风格、 τ 值、当前 `longing` %、phase 标签、进度条（带 0.15/0.35/0.70 三条阈值刻度线）、预计各 phase 进入时间、离线时长、当前胶囊、PA/NA。



异常警报：longing > 0.8 超过 24h、全员同时 protest。

工程踩坑

1. **闭集 > 开集**：固定词典比让 LLM 自由发挥更可靠。自由发挥会同义词爆炸、坐标聚集。
 2. **AI 选词，词典给坐标**：评分准确度 70% 由词典决定，30% 由模型决定。好词典 + 弱模型 $\approx$ 无词典 + 强模型。
 3. **LLM 的 PA/NA 数字不可信**：从词典 V/A 算，LLM 裸数字只做门控信号。
 4. **心情注入要隐性不要显性**：不说“你必须表现得紧张”，而是给情绪上下文让 LLM 自己判断。最初试过强制指令，角色变成了演员，每句话都在点破“我好紧张啊”。
 5. **装饰心情只取最新一条参与融合**：否则历史装饰心情累积会污染 PA/NA。
 6. **均值回归是必需的**：没有 BOU drift，一次负面事件就能让角色永远低落（正反馈环）。这是系统上线后第一个遇到的严重 bug。
 7. **逃逸阀不能太灵敏**：连续 batch 阈值设 3 而非 1，防止单次评分误判触发。
 8. **onset 防止情绪瞬间跳变**：没有 onset，刚写入的事件 weight=1 会造成不自然的突变。
 9. **OCC 要保守**：max ± 0.1 加性调节，新特性宁可弱一点也不能炸。
 10. **状态快照比完整历史好**：试过把过去 7 天的 PANAS 评分全塞进 prompt，token 爆炸且 LLM 被信息淹没。只塞“此刻”的快照，效果反而更好。
 11. **Longing 按角色独立计算**：曾出现跟一个角色说话所有角色 longing 归零的 bug，因为 SQL 缺少角色过滤条件。
 12. **前后端改完都要验语法**：曾因 service-worker `.then()` 悬空导致整个 script 块 `SyntaxError`，所有前端函数未注册，系统全挂。
-

学术参考文献

情绪系统

1. Watson & Clark (1988) — PANAS PA/NA 双轴模型
2. Russell (1980) — Circumplex V/A 二维情感坐标
3. Wixted & Ebbesen (1991) *Psychological Science* — 幂律遗忘曲线

4. Wixted (2004) *Annual Review of Psychology* — 幂律衰减综述
5. Verduyn & Lavrijsen (2015) *Motivation & Emotion* — 情绪持续时间 × 重要性
6. Walker & Skowronski (2009) *Applied Cognitive Psychology* — Fading Affect Bias
7. Rutledge et al. (2014) *PNAS* — 统一事件加权 ($\gamma \approx 0.79$)
8. Gebhard (2005) *ALMA* — Personality → threshold/peak
9. Velasquez (1998) *TAME* — Personality → emotion parameters
10. Becker-Asano & Wachsmuth (2010) *WASABI* — Primary/secondary emotions
11. Marsella & Gratch (2006) *EMA* — Coping mechanisms
12. Ortony, Clore & Collins (1988) *OCC* — Goal-based appraisal
13. Scherer (2009) *CPM* — Appraisal latency / onset
14. Loossens et al. (2020) *PLoS Comp Biol* — Affective Ising Model / BOU
15. van de Leemput et al. (2014) *PNAS* — Critical Slowing Down
16. Diener, Lucas, Scollon (2006) *American Psychologist* — Set-point theory
17. Cacioppo & Berntson (1994) — Evaluative Space Model (ESM) PA/NA 互抑
18. Larsen et al. (2001) *JPSP* — 混合情绪实验 (~10% 被试)
19. Kuppens & Verduyn (2017) *Current Opinion in Psychology* — 情绪动力学
20. Houben et al. (2015) *Psychological Bulletin* — MSSD 情感不稳定性
21. Lee, Yu et al. (2022) *ACM TALLIP* — Chinese EmoBank / CVAW

依恋控制系统

22. Bowlby (1969/1982) — 依恋行为系统理论
23. Robertson & Bowlby (1952) — Protest → Despair → Detachment 三阶段
24. Robertson & Robertson (1968) — Little John 案例 (18 月男孩 9 天分离)
25. Sternberg (1986/1988) — 三角爱情理论 (I/P/C)
26. Hazan & Zeifman (1994) — 依恋功能发展顺序
27. Heffernan et al. (2012) — 依恋功能可能发展更快
28. Diamond (2008) "Every Time You Go Away" — 42 对情侣分离数据

29. Sbarra & Emery (2005) — 分手后 love/longing curvilinear 衰减
30. Sbarra & Hazan (2008) — 共调节→失调节→自调节框架
31. Fraley & Shaver (1998) — 机场分离研究, 即时 proximity seeking
32. Coan (2006) — Social Baseline Theory, 接触→即时 calming
33. Beckes & Coan (2011) — SBT 扩展
34. Vormbrock (1993) — 军事部署分离, 成人 detachment weeks-months
35. Baumeister & Leary (1995) — Need to Belong, 归属需求不满 → NA
36. Jiang & Hancock (2013) — LDR 数据, 88% 每天联系
37. Vanderbilt (2025) — 焦虑型发更多消息, 回避型更少
38. Drouin & Landgraff (2012) — 回避依恋→更少发短信

Built on top of [Ombre-Brain](#) | 7600+ lines | 20,127 词典 | 5 CME directions + ESM + Bowlby attachment