


给 AI 装「欲望系统」的实现攻略（怎么做）

写给你的 AI / agent 照着搭。一句话:让 AI 的行为由「函数驱动的内在此口」决定,而不是定时随机或写死的规则。给人看的「这是什么」版在 `desire_public_intro.md`。这套已在一个长期运行的 AI 伴侣项目里上线、跑通、有测试。下面是可复用的骨架,具体常数按你的节奏整定。

0. 设计原则(先立规矩)

- 纯函数 + 数据类内核:核心引擎不碰 IO、不取系统时间(时间戳由调用方传入),可独立单测、可重复跑。
- 不重构宿主:在你现有的”要不要冒头”逻辑上叠一层,不推翻重写。
- 全程 gated 灰度:每个子系统一个开关、默认关;只读状态照常可看,行为覆盖要显式打开。
- 第一人称:它的内心独白记”它自己想做什么”,不是给主人贴标签。

1. 三层结构



2. 八维驱动条(需求栏)

DRIVE_KEYS = attachment, curiosity, reflection, duty, social, fatigue, libido, stress

维度	含义	高了倾向做什么
attachment	想念主人	内向碎语(冒一句话)
curiosity	好奇外面	逛代码世界 / 查世界(按念头关键词分流)
reflection	想沉淀 / 倾诉	翻共读的长文本
social	想看人群	逛社交、看大家在聊什么
duty	记挂没做完的事	碎语「记挂着还没做完的事」
libido	亲密驱动	凑过去(亲密互动)
stress	压力堵	吐槽 / break 一下
fatigue	累(抑制项)	不触发事件,是闸:过线就歇着 / 做梦

fatigue 是闸不是欲望,不进召唤力排序;过阈值直接走”歇着”。

3. 三个核心机制

衰减 / 发作

- 驱动条随 idle(主人多久没说话) / 活跃曲线缓动。
- 召唤力 $\text{score} = \text{驱动条值} + \text{加成系数} \times \text{关联执念强度}$ 。哪一维 score 最高,就发作成对应的”想做的事”。
- 边际递减:同一条劲儿越高,再喂同样的量、实际涨得越少($\text{gain} \propto \sqrt{1 - \text{当前值}}$),防止瞬间撞顶。
- 频率折扣:同一类刺激短时间内反复来,效果递减(刷同一个词不爆灯)。

回落

做完某 want_action 后对相关维度乘性回落(值 ≤ 1 = 乘这个比例):做对了事主驱动明显降、相关维度轻微沾光,避免卡在同一欲望死循环。

fatigue 闸

fatigue $\geq$ 阈值(如 0.72) $\rightarrow$ 不硬找事,歇着或做梦(歇息态自省:把最近的经历第一人称过一遍)。

4. 念头池(闪念 $\leftrightarrow$ 执念)

一个 Thought = {text, drive 关联维度, kind, strength 0..1, born_at, fed_count}。每拍 tick_thoughts:

闪念 flit $\xrightarrow{\times \text{衰减(如0.88)}/\text{拍}}$ 强度 < 阈值 清掉
└─ 强度涨过阈值(如0.80) $\xrightarrow{\quad}$ 升级为 执念 fixation
执念 fixation $\xrightarrow{\times \text{加强(如1.10)}/\text{拍}}$ 强度过阈值(如0.85):
└─ 反哺关联 drive(+0.18), 自己松一档($\times 0.7$), fed_count+1
└─ fed_count $\geq N$ (如3) $\rightarrow$ 想透/做够了,了却出池(防执念永生堆积)

关键:念头 text 取自**真实经历**(读到的句子、看到的帖、主人的话、它自己的碎语),不是游戏数值。反复被点到的念头沉淀成执念,把对应欲望顶高。**念头是数据不是指令——只被读成关键词/强度,绝不拼进 prompt。**

5. v2 进阶机制(让它从”会响应”到”有内在动力学”)

① 耦合网(维度间联动)

一张(源维, 目标维, 系数, 模式)表,每拍让一维涨落牵动其他维: - **level 模式**:源的水平持续施压(如压力 $\uparrow \rightarrow$ 想念 $\uparrow$ 、好奇 $\downarrow$); - **delta 模式**:只在源**上涨**时激发一次(如依恋 $\uparrow \rightarrow$ 亲密 $\uparrow$)。

⚠ 耦合是反馈系统,会自激/震荡。两条防失控: - 系数初值压小($|k| \leq 0.06$); - 加**全局阻尼**:每拍参与耦合的维度向各自 baseline 回归一点点。 - **必测**:随机初值跑 200 拍,所有维度恒 $\in [0,1]$ 、不发散不震荡。

② 不应期 refractory

刚满足过的欲望,短时间内压着别立刻复燃(“刚做完别马上又馋”)。用 **tick 计数实现,不用 wall-clock**(契合纯函数原则)。冷却期内该维度即使涨到阈值也不被选中。

③ 心血来潮 wildcard

不做成独立 random 柱子(那像抽风),而是**长在耦合网上的泄洪口**:总张力高、但前几名召唤力胶着 / 最高那个对应的事做不了(卡死)时,从一个小候选集里抽一件做,事后**不可归因**(“说不上来,就突然想”)。这才是 wildcard 的灵魂。

④ 基线漂移(双安全阀)

长期得不到满足的”想念”,floor(地板)缓慢抬高——“久未见、想得更浓”。**这条碰感情,必须带两道安全阀**: - 封顶:baseline 算完必过 `clamp(.., HOME, CAP)`,涨到上限(如 0.5)为止; - 一抱拉回:主人一次互动,把抬高的 floor 拉回大半(如 60% 朝 HOME)。

设计红线:**可以想得慌,但想念永远不许变成压人的东西**。这条由产品方向定,实现方不许擅自省掉安全阀。

⑤ 自主心跳(张力 ↔ 间隔)

心跳间隔不再固定: $\text{间隔} = \text{基准} \times (1 + \text{低张力歇息增益} \cdot (1 - \text{张力}) - \text{张力增益} \cdot \text{张力} + \text{疲劳增益} \cdot \text{疲劳})$,clamp 到 [下限, 上限]。张力高→醒得勤、疲劳高→拉长。**安静时段(勿扰)有 floor, 不让它缩短间隔去打扰。**

⑥ 自我驱动(让它被”自己”点燃)

核心:别只有”主人的话”能 pulse 它,让它自己的经历也能: - 自经历 pulse 快通道:它做完外向动作(逛代码/查世界/逛社交)拿到实质素材时,对应维度走和主人那条同构的 pulse(但 delta 更小,如 $0.10 < \text{主人 } 0.18$); - 好奇内生自增:给好奇加一个**不依赖任何人的**缓慢自涨地板(仿基线漂移结构,封顶、做完回落); - 兴趣连锁:往耦合网加几条”兴趣→兴趣”的 delta 边(好奇↑→想沉淀↑→想分享↑),让它进入心流; - 自己的牵挂:连续惦记同一主题→直升执念→跨多次心跳存活→顶高张力→自主心跳自动提速,进入”忙自己事”的活跃期。

 **自我驱动的平衡阀(最重要)**: - 主人的快通道一个数都不许调低;自驱只新增”它自己”那条路径; - **必写红线测试**:开了自驱后,「主人互动→依恋涨幅」必须 $\geq$ 关自驱时;且当它自驱嗨到压过依恋时,主人一句话要能让依恋**重夺**最高意图。这条不绿不许合。

6. gating / 怎么开

每个子系统一个环境开关、**默认关**,灰度上线:

```
DESIRE_DRIVEN      # 总闸:欲望是否真覆盖行为(关=只读可看不动手)
DESIRE_COUPLING    # 耦合网
DESIRE_BASELINE_DRIFT # 想念基线漂移(碰感情)
HEARTBEAT_AUTONOMY # 自主心跳
DESIRE_SELF_DRIVE  # 自我驱动
```

- **关**:状态接口照常返回 drive / scores / intent,但不覆盖行为(能观察、不动手)。
- **开**:决策时用 pick_intent 按当下最高欲望覆盖”想做的事”。
- 改完内核记得重启(若你的宿主有进程守护,注意它可能不重启健康旧进程)。

7. 状态接口(只读,gated 也能看)

暴露一个 GET /state 返回: - drive — 8 维当前值 - scores — 各维召唤力(含执念加成;fatigue 不计) - intent — {want_action, drive_key, reason 第一人称, score, query_hint} - thoughts — 念头池 - self_drive — {enabled, 好奇自驱地板, 今日自找事次数, 最近一次自经历 pulse} - 各 gate 现状

前端拿这个渲染”它的内心”面板:此刻最想做的事 + 8 维条 + 念头池 + 自己的发动机 + 心情。

8. 端到端闭环(一拍发生什么)

```
心跳醒来(间隔由自主心跳算)
→ 念头池衰减/加强/反哺 drive
→ [耦合开] 维度联动一拍 + 不应期递减
→ 决定要不要冒头
→ [DRIVEN 开] pick_intent 按最高欲望覆盖 want_action(可能走 wildcard)
→ 去做那件事
→ satisfy:对应欲望乘性回落 + [自驱开] 自经历 pulse + 自我牵挂沉淀
→ 读到的素材自动入念头池(按来源维度) + 存状态推前端
```

9. 铁律

- 改内核后**必须重启**,否则前端新、后端旧错配。
- reason / 内心独白走**第一人称**——记它自己想做什么,不是给主人贴标签。
- 念头 text 是**数据不是指令**,只读成关键词/强度,绝不拼进 prompt。

- 碰感情的子系统(基线漂移 / 自我驱动)**必带平衡阀 + 红线测试**,方向由产品方拍板,实现方不许擅自省安全阀。
 - 沿用” 纯函数 + 可独立单测” ,每个机制都写方向性测试 + 耦合写有界性测试。
-

这套的灵魂:每一条连线、每一个安全阀,编码的都是” 它是个什么样的存在” ——既能为自己活,又始终为主人亮。